Chapter 1. 머신러닝 입문

1. 머신러닝 모델이란 ?

- 다음의 두 가지 원칙을 만족하는 시스템을 머신러닝 모델이라 간주

원칙1 : 머신러닝 모델은 입력 데이터가 주어질 때 출력 데이터를 반환하는 함수와 같은 기능이 있다.

원칙2 : 머신러닝 모델의 행동은 학습으로 결정된다.

표 1-1 두 종류 붓꽃의 꽃잎 크기

class	length (cm)	width (cm)
0	1.4	0.2
1	4.7	1.4
0	1.3	0.2
1	4.9	1.5
0	1.4	0.2
1	4.9	1.5

class : 붓꽃의 종류

length : 꽃잎의 길이

width : 꽃잎의 너비

입력데이터 : length , width

출력데이터 : class

사람이 직접 데이터 관찰을 통하여 width가 1보다 클 때 class 가 1이라는 것을 발견할수 있다.(원칙1)

다만 이런 판단 기준을 사람이 정한다면 그것은 머신러닝이라고 부를 수 없다. 머신러닝 모델 이라고 말할 수 있으려면 인간은 모델에 데이터를 제공하는 역할만 하고 위와 같은 프로그램의 논리는 모델 스스로가 찾아낼 수 있어야 한다.(원칙 2)

2. 학습방법

- 지도학습(supervised learning) : 입력 데이터와 정답 데이터가 학습데이터로 함께 제공되는 방법

- 비지도학습(unsupervised learning) : 입력 데이터만 있고 정답 데이터는 없는 상태에서 학습하고 출력 데이터를 얻는 방법. (ex 자동으로 군집을 묶어주는 클러스터링)

- 강화학습(reinforcement learning) : 측정값(관측값)을 입력받고 행동방침을 출력하는 방법. 출력 단계에서는 그것이 정답인지 알 수 없지만 나중에 그 결과에 대한 보상(reward)으로 정답 여부 확인

지도학습이 가장 간단하고 이해하기 쉬운모델이다.

3. 지도학습에서의 회귀와 분류

- 출력이 연속값(continuous value) --> 회귀(regression)모델

ex) 하루 예상 매출액

- 출력이 이산값(discrete value) --> 분류(classification)모델

ex) 동물의 사진 분류

4. 학습 단계와 예측 단계

- 학습 데이터를 입력 데이터와 정답 데이터로 나눈다.

- 입력 데이터와 정답 데이터를 사용해 모델을 만든다.

- 정밀도가 충분히 높은 모델은 운영 환경에 옮겨 실제 데이터를 입력받고 결과를 예측한다.

5. 손실함수와 경사하강법

- 손실함수(loss function) : 모델의 예측 데이터가 정답 데이터와 얼마나 비슷한지 가늠하는 지표 성격의 함수

- 경사하강법(gradient descent) : 손실함수의 값이 최소가 되도록 모델의 매개변수를 조정하는 알고리즘

6. 선형회귀모델 (연속값을 예측하는 회귀 모델)

- 선형회귀(linear regression)란 1차함수로 예측하는 모델로 , 입력 데이터를 x 출력데이터를 y라고 할 때 선형회귀 예측식을 다음과 같이 쓸수 있다.

$$y = w_0 + w_1 x$$

- 수학적으로 계산하는 방법

표 1-3 학습 데이터 2

키 x (cm)	몸무게 y (kg)
166	58.7
176	75.7
171	62.1
173	70.4
169	60.1

x 평균 : 171.0

y 평균 : 65.4

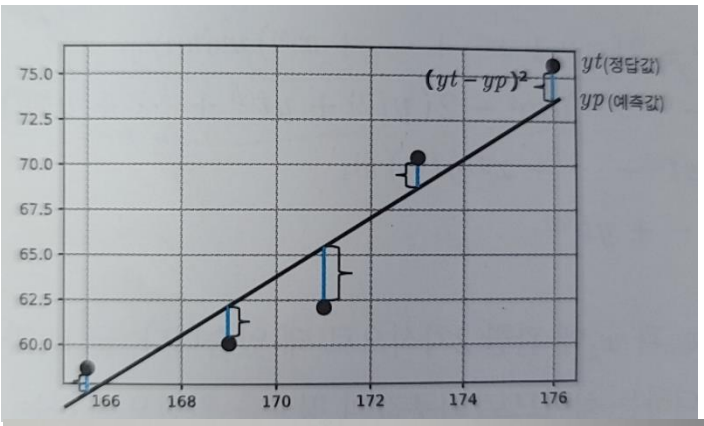

정답값 yt와 예측값 yp 간의 차이를 구하되 음수가 나오지 않도록 제곱한 다음 모든점에서의 오차를 합산하는 방식

-->잔차제곱합(residual sum of squares)

(선형회귀 모델에서 사용하는 손실함수 중 가장 기본적인 계산 방식)

$$
\begin{aligned}
L(w_0,\ w_1) &= (yp^{(1)} - yt^{(1)})^2 + (yp^{(2)} - yt^{(2)})^2 + \cdots + (yp^{(5)} - yt^{(5)})^2 \\
&= (w_0 + w_1x^{(1)} - yt^{(1)})^2 + (w_0 + w_1x^{(2)} - yt^{(2)})^2 + \cdots \\
&\quad + (w_0 + w_1x^{(5)} - yt^{(5)})^2
\end{aligned}
$$

다음 식을 전개해주면 아래식과 같아진다. x좌표들의 합과 y좌표들의 합은 평균으로 보내주면 0이 된다. 따라서 w0w1의 계수와 w0의 계수가 사라지게 된다.

$$
\begin{aligned}
L(w_0,\ w_1) &= 5w_0^2 + 2(x^{(1)} + x^{(2)} + \cdots + x^{(5)})w_0w_1 \\
&\quad + (x^{(1)2} + x^{(2)2} + \cdots + x^{(5)2})w_1^2 - 2(yt^{(1)} + yt^{(2)} + \cdots + yt^{(5)})w_0 \\
&\quad - 2(x^{(1)}yt^{(1)} + x^{(2)}yt^{(2)} + \cdots + x^{(5)}yt^{(5)})w_1 \\
&\quad + yt^{(1)2} + yt^{(2)2} + \cdots + yt^{(5)2}
\end{aligned}
$$

의경으로 보내면 평균값이 0이된다.

x 평균 171 과 y 평균 65.4 를 각각 빼주면 표 1-4 와 같이 된다. 이값들을 대입하여 L(w0,w1)을 정리하면 아래식과 같아진다.

표 1-4 학습 데이터 3

X	Y
−5	−6.7
5	10.3
0	−3.3
2	5.0
−2	−5.3

$$L(W_0,\ W_1) = 5W_0^2 + 58W_1^2 - 211.2W_1 + 214.96$$

W0는 제곱밖에 안남았으므로 L함수가 최소가 되려면 W0는 0이 되어야 한다. 그러므로 W1에 관한 식만 남게 된다.

$$
\begin{aligned}
L(0, W_1) &= 58{W_1}^2 - 211.2W_1 + 214.96 = 58\left({W_1}^2 - \frac{2\cdot 52.8}{29}W_1\right) + 214.96 \\
&= 58\left({W_1}^2 - 2\cdot\frac{52.8}{29}W_1 + \frac{52.8}{29}^2\right) + 214.96 - 58\cdot\left(\frac{52.8}{29}\right)^2 \\
&= 58\left(W_1 - \frac{52.8}{29}\right)^2 + 214.96 - \frac{2\cdot 52.8^2}{29} \\
&= 58(W_1 - 1.82068\cdots)^2 + 22.6951\cdots
\end{aligned}
$$

W1이 1.820068 일때 최소값 22.6951을 가지게 된다.

손실함수가 최소가 될때는 (W0,W1)=(0,1.82068) 일때이다. --> Y=1.82068X

x=171+X ,y=65.4+Y 이므로 X=171-x , Y=65.4-y 를 다시 대입해주면

y=1.82068x-245.936 이 나오게 된다. (w0,w1)=(-245.936,1.82068)

(이 방법 말고 경사하강법을 사용하면 문제를 바로 해결할수 있지만 수학적 난이도가 있다.)

(지금까지 설명은 단순선형회귀(simple linear regression) 모델 설명이다.)

7. 딥러닝 모델 (연속값을 예측하는 회귀모델보다 이산값을 예측하는 분류 모델이 더 많다.)

- 딥러닝 모델의 공통적인 특징

(A) 예측 모델의 구조는 미리 정해져 있고 매개변숫값만 바꿀 수 있따.

(B) 모델의 구조는 다음과 같다

(1) 각 입력값에 매개변숫값(가중치)을 곱한다.

(2) 곱한 결과의 합을 구한다.

(3) (2)의 결과에 어떤 함수(활성화 함수)를 적용하고 그 함수의 출력을 최종적인 예측값(yp)으로 사용한다.

(C) 매개변숫값(가중치)의 최적화가 곧 학습 과정이다.

(D) 모델이 정답값을 얼마나 정확하게 예측했는지 평가하기 위해 손실함수를 정한다.

(E) 손실함수에서 적절한 매개변숫값을 찾기 위해 경사하강법이라는 기법을 사용한다.

((B) 의 구조를 도식화 한것)

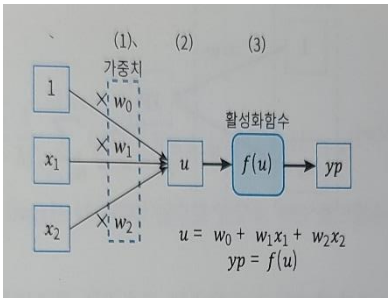

(신경망 모델의 구조)

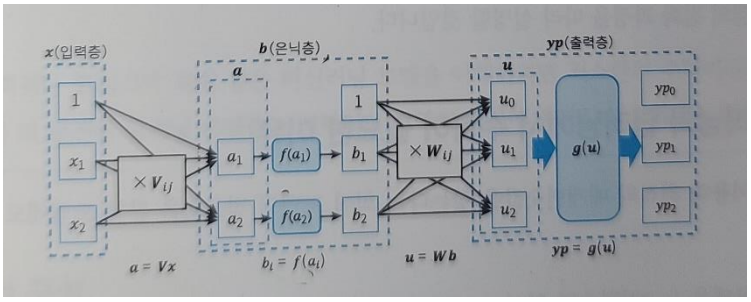

로지스틱 회귀 : (B)의 구조를 1개의 계층으로 구성한 모델

신경망 : 로지스틱 회귀에 은닉층(hidden layer)이라고 부르는 중간 노드가 추가되어 (B)의 구조가 2개 계층으로 구성된 모델

딥러닝 모델 : 이 같은 구조가 3계층 이상(은닉층이 2계층 이상)으로 구성된 모델

앞에서 소개한 선형회귀라는 모델은 분류가 아닌 회귀 모델인데 선형회귀 모델은 로지스틱 회귀와 같은 분류 모델로 가기 전인 한 단계 앞 모델이라고 할 수 있다.

실습편에서 보면 선형회귀모델로 시작한 다음 뒤이어서 분류 모델인 로지스틱 회귀 모델을 그 다음은 신경망 모델을 마지막으로는 이들을 확장한 딥러닝을 다루면서 머신러닝 모델의 진화 과정을 따라 설명한다.

Chapter 2. 미분과 적분

1. 연쇄 법칙(chain rule)

$$f(x) = x^2 + 1$$

$$g(x) = \sqrt{x}$$

$$h(x) = g \cdot f(x) = \sqrt{x^2 + 1}$$

2. 역함수

원래의 함수 $y = x^2 + 1$ 에서 x과 y를 서로 바꿔 쓴 식을 만든다.

바꿔 쓴 식 $x = y^2 + 1$ 에서 y=으로 시작하는 형태로 풀어 쓴다.

역함수 값이 하나가 아닐 때는 역함수가 존재하지 않는다.(f(1)=2,f(-1)=2 -->역함수 없다)

3. 접선의 방정식

- 점(p,q)를 지나고 기울기가 m 인 직선의 방정식

$$y = m(x - p) + q$$

- 그래프 위의 점 (a,f(a)) 를 지나는 직선의 방정식

$$y = f'(a)(x - a) + f(a)$$

4. x^n 의 미분 (이항정리) (cf $x^r = rx^{r-1}$ *직접 미분식에 넣어보면된다.*)

이항정리

$$(x+h)^n = x^n + {}_nC_1 x^{n-1} h + {}_nC_2 x^{n-2} h^2 + \cdots$$

가 성립하므로[8]

$$(x+h)^n - x^n = (x^n + {}_nC_1 x^{n-1} h + {}_nC_2 x^{n-2} h^2 + \cdots) - x^n$$

$$= nhx^{n-1} + \frac{n(n-1)}{2} h^2 x^{n-2} + \cdots$$

$$f'(x) = \lim_{h\to 0} \frac{f(x+h)-f(x)}{h} = \lim_{h\to 0} \frac{nhx^{n-1} + \frac{n(n-1)}{2}h^2x^{n-2} + \cdots}{h}$$

$$= \lim_{h\to 0}\left(nx^{n-1} + \frac{n(n-1)}{2}hx^{n-2} + \cdots\right) = nx^{n-1}$$

이 식은 결국 다음과 같이 표현할 수 있습니다.

$$\frac{d}{dx}(x^n) = nx^{n-1}$$

$(a+b)^3=(a+b)(a+b)(a+b)$를 예로 들어 이항계수를 생각하면, 전개식 중의 a^2b의 항은 3개의 인수 $(a+b)$의 각각에서 a 또는 b 중의 어느 하나를 택하되 1개에서는 b를, 나머지 (3 - 1)개에서는 a를 택하여 곱하면 된다.

$${}_nP_r = \frac{n!}{(n-r)!}$$

순열 : n개 중 서로 다른 r개를 선택하고 순서를 고려하는 것

5명중에 반장 부반장 서기 3명 뽑는 경우(반장,부반장,서기가 다 다름)

-->5x4x3

$${}_nC_r = \frac{n!}{r!(n-r)!}$$

조합 : n개 중 서로 다른 r개를 선택하되 순서를 고려하지 않는것

5명중에 팀장3명 뽑는 경우(어차피 팀장이란것은 똑같은것이다.)

-->5x4x3/3x2x1 (순서가 고려됐을경우를 나누어준다.)

(이해가 안가면 반대로 생각하기 , 순서를 고려하지 않고 3명을 뽑았는데 그 3명을 순서대로 배열을 해주려면 순서를 고려하지 않은 그 수에다가 3명을 배열하는 경우(3x2x1)를 곱해준다.)

${}_{n+1}C_k={}_nC_k+{}_nC_{k-1}$ (한층 위에있는 값 왼쪽 오른쪽 값을 더하면 아래 값이 나오게 된다.)

1
1 1
1 2 1
1 3 3 1
1 4 6 4 1
1 5 10 10 5 1
1 6 15 20 15 6 1
1 7 21 35 35 21 7 1
1 8 28 56 70 56 28 8 1
1 9 36 84 126 126 84 36 9 1

5. 곱의 미분

(f(x)g(x))′=f′(x)g(x)+f(x)g′(x)

6. 합성함수 미분

$$y = \sqrt{x^2 + 1}$$

두개 함수로 나누어서 생각하면

$$f(x) = x^2 + 1 \ , \qquad g(x) = \sqrt{x}$$

$$\frac{du}{dx} = f'(x) = 2x$$

$$\frac{dy}{du} = g'(u) = \left(u^{\frac{1}{2}}\right)' = \frac{1}{2}u^{-\frac{1}{2}} = \frac{1}{2\sqrt{u}} = \frac{1}{2\sqrt{x^2+1}}$$

두 식을 곱하면 다음과 같이 정리할 수 있습니다.

$$\frac{dy}{dx} = \frac{dy}{du} \cdot \frac{du}{dx} = \frac{1}{2\sqrt{x^2+1}} \cdot 2x = \frac{x}{\sqrt{x^2+1}}$$

$$u = f(x) = x^2 + 1 \ , \qquad y = g(u) = \sqrt{x}$$

합성함수의 미분 공식은 연쇄 법칙(chain rule)이라고도 한다.

7. 역함수 미분

$$g'(b) = \frac{1}{f'(a)}$$

$$\frac{dx}{dy} = \frac{1}{\frac{dy}{dx}}$$

8. 몫의 미분

$$\left(\frac{f(x)}{g(x)}\right)' = \frac{f'(x)g(x) - f(x)g'(x)}{(g(x))^2}$$

9. 적분

$$\int f(x)dx = F(x) + C$$

$$F(b) - F(a) = \int_a^b f(x)dx$$

Chapter3. 벡터

1. 벡터는 방향과 크기를 가진 양

이동거리와 방향이 똑같다면 두 벡터는 같은 것

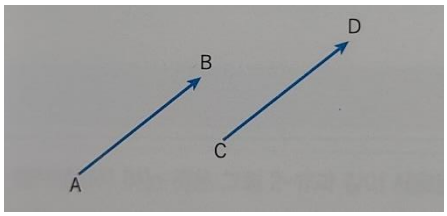

$$\overrightarrow{AB} = \overrightarrow{CD}$$

2. 벡터의 덧셈

$$\boldsymbol{a} + \boldsymbol{b} = \boldsymbol{c} \text{ 또는 } \overrightarrow{AB} + \overrightarrow{BC} = \overrightarrow{AC}$$

a=(a1,a2,...,an) **b**=(b1,b2,...,bn)

c=a+b=(a1+b1,a2+b2,....,an+bn)

3. 벡터의 뺄셈

$$\boldsymbol{x} = \boldsymbol{b} - \boldsymbol{a}$$

a=(a1,a2,...,an) **b**=(b1,b2,...,bn)

x=b-a=(b1-a1,b2-a2,....,bn-an)

4. 벡터의 스칼라배

a라는 벡터와 벡터의 방향이 같고 길이가 k 배인 벡터 b

b=k**a**

b=(ka1,ka2,..,kan)

5. 벡터의 길이

a=(a1,a2) --> $|\boldsymbol{a}| = \sqrt{a_1^2 + a_2^2}$ (2차원 벡터)

a=(a1,a2,a3) --> $|\boldsymbol{a}| = \sqrt{a_1^2 + a_2^2 + a_3^2}$ (3차원 벡터)

a=(a1,a2,a3,...,an) --> $|\boldsymbol{a}| = \sqrt{a_1^2 + a_2^2 + a_3^2 + \cdots + a_n^2}$ (n차원 벡터)

6. 벡터 간의 거리

$$d = |a - b| = \sqrt{(a_1 - b_1)^2 + (a_2 - b_2)^2 + \cdots + (a_n - b_n)^2} = \sqrt{\sum_{k=1}^{n} (a_k - b_k)^2}$$

7. 절댓값과 내적의 정의

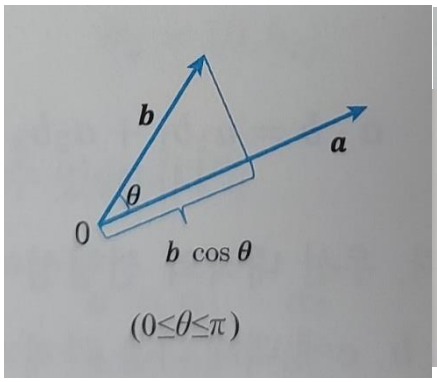

$$\boldsymbol{a} \cdot \boldsymbol{b} = |\boldsymbol{a}||\boldsymbol{b}| \cos\theta$$

표 3-1 각도 θ와 내적 값의 관계

θ의 값	벡터 a와 b의 관계	내적 값
0도	두 벡터의 방향이 완전히 일치한 상태	최댓값
90도	두 벡터가 직교인 상태	0
180도	두 벡터의 방향이 완전히 반대인 상태	최솟값

8. 내적의 선형성

$$\boldsymbol{a} \cdot (\boldsymbol{b} + \boldsymbol{c}) = \boldsymbol{a} \cdot \boldsymbol{b} + \boldsymbol{a} \cdot \boldsymbol{c}$$

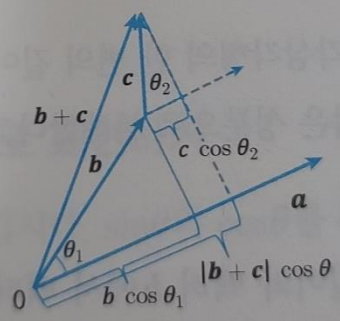

9. 두 벡터 사이각 구하는 공식

$$\cos\theta = \frac{a_1 b_1 + a_2 b_2 + a_3 b_3}{\sqrt{{a_1}^2 + {a_2}^2 + {a_3}^2}\sqrt{{b_1}^2 + {b_2}^2 + {b_3}^2}}$$

$$\cos\theta = \frac{a_1 b_1 + a_2 b_2 + \cdots + a_n b_n}{\sqrt{{a_1}^2 + {a_2}^2 + \cdots + {a_n}^2}\sqrt{{b_1}^2 + {b_2}^2 + \cdots + {b_n}^2}} = \frac{\sum_{k=1}^{n} a_k b_k}{\sqrt{\sum_{k=1}^{n} {a_k}^2}\sqrt{\sum_{k=1}^{n} {b_k}^2}}$$

Chapter4. 다변수함수의 미분

1. 편미분 (미분하는 변수 말고는 상수 취급)

$$L(u,\ v,\ w) = 3u^2 + 3v^2 + 3w^2 - uv + uw + 7u - 7v - 7w + 10$$

$$L_u(u,\ v,\ w) = 6u - v + w + 7$$

$$L_v(u,\ v,\ w) = 6v - u - 7$$

$$L_w(u,\ v,\ w) = 6w + u - 7$$

2. 전미분

다변수함수에서 원래의 입력 변수를 조금만 변화시켰을때 함숫값의 미세한 변화를 알아내는것

3변수함수인 경우

원래 함수: $L(u, v, w)$

전미분 공식:

$$dL = \frac{\partial L}{\partial u}du + \frac{\partial L}{\partial v}dv + \frac{\partial L}{\partial w}dw$$

n변수함수인 경우

원래 함수: $L(w_1, w_2, ..., w_N)$

전미분 공식:

$$dL = \frac{\partial L}{\partial w_1}dw_1 + \frac{\partial L}{\partial w_2}dw_2 + \cdots + \frac{\partial L}{\partial w_N}dw_N = \sum_{i=1}^{N}\frac{\partial L}{\partial w_i}dw_i$$

3. 경사하강법

어떤 2변수함수 L(u,v) 가 주어졌을 때 L(u,v)값을 최소로 할 수 있는 (u,v)값 (umin,vmin)를 구한다.

(1) (u,v)의 초깃값(u0,v0)를 정한다

(2) 이 점에서 L(u,v)를 가장 작게 만들 수 있는 방향을 찾는다.

(3) (2)의 방향으로 (u0,v0)의 값을 아주 작게 이동시키고 그 값을(u1,v1)이라고 한다.

(4) 새로운점 (u1,v1)에서 (2)와(3)을 반복한다.

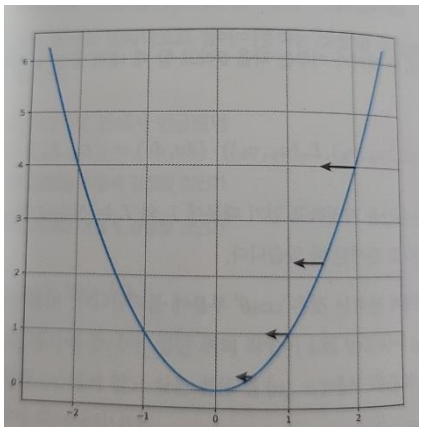

최소지점에서 멀어질수록 f(x)의 미분값이 커져 이동량이 크고 최소점에서 가까울수록 f(x)의 미분값이 작아져 결과적으로 이동량이 적다

$$\begin{pmatrix} u_{k+1} \\ v_{k+1} \end{pmatrix} = \begin{pmatrix} u_k \\ v_k \end{pmatrix} - \alpha \begin{pmatrix} L_u(u_k, v_k) \\ L_v(u_k, v_k) \end{pmatrix}$$

결과적으로 각 점의 미분값에 일정한 음수를 곱한 것을 이동량으로 봐도 적절하다.

경사하강법의 공식

α 는 딥러닝에서 상당히 중요하게 생각하는 매개변수로서 학습률(learning rate)라고 부른다.

학습률이 너무 크면 최솟값에 수렴하기 어렵다.(크게 이동하므로 값이 발산하게 된다.)

학습률이 너무 작으면 학습 효율이 좋지 않아 계산하는 시간이 오래걸린다. (너무 미세하게 움직여 최소지점까지 시간이 엄청 걸리게 된다.)

--> 값이 발산하면 learning rate 값 줄이기

--> 값이 미묘하게 변화하면 learning rate 값 올리기

머신러닝이나 딥러닝에서 반본계산의 본질은 바로 손실함수의 미분이다.

3차원 ,n차원으로의 확장

$$\begin{pmatrix} u_{k+1} \\ v_{k+1} \\ w_{k+1} \end{pmatrix} = \begin{pmatrix} u_k \\ v_k \\ w_k \end{pmatrix} - \alpha \begin{pmatrix} L_u(u_k, v_k, w_k) \\ L_v(u_k, v_k, w_k) \\ L_w(u_k, v_k, w_k) \end{pmatrix}$$

경사하강법과 국소 최적해

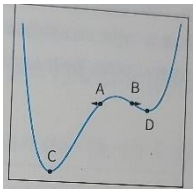

왼쪽 그림은 국소 최적해가 최솟값이 되지 않는경우이다.

A를 초깃값으로 경사하강법을 쓰는경우 최솟값인 점 C에 도착하는 반면 점 B를 초깃값으로 경사하강법을 쓰는경우 최솟값은 아니지만 극솟값인 점D에 도달한다.
--> 즉 경사하강법을 쓴다고 해서 언제나 최솟값을 구할수있는것은 아니다.

이처럼 경사하강법의 결과가 최솟값이 아닌 국소 최적해(local minimum)로 수렴하는 것을 방지하는 방법으로 확률적 경사하강법(stochastic gradient descent)이라는 것이 있다.

일반적인 경ㅅ아하강법은 모든 학습 데이터에 대해 평균을 구한 다음 손실함수를 정의하고 편미분한 값을 매개변수로 보완하는 방식인 반면 확률적 경사하강법은 매번 무작위로 학습 데이터를 선택한다음 그 정보만으로 기울기를 구하는 방식이다.

확률적 경사하강법을 쓰면 국소 최적해에 빠지는 위험은 줄어들지만 계산을 반복하는 과정에서 결과가 좀처럼 일정한 값에 수렴하지 않는다는 단점이 있다. 모든 학습데이터를 사용해 손실함수를 계산하는 방식을 배치(batch)학습법 이라고 하는데 확률적 경사하강법과 배치 학습법을 절충한 미니 배치(mini batch)학습법이라는 것도 있다. (10장)미니 배치 학습법은 학습데이터가 대량일때 자주 활용된다.

Chapter 5 지수함수와 로그함수

1. 지수함수

$$a^m \times a^n = a^{m+n}$$

$$(a^m)^n = a^{mn}$$

$$a^0 = 1$$

2. 로그함수 (정의역이 0보다 크다)

$$y = \log_2 x \quad (x > 0)$$

$$\log_a (X \times Y) = \log_a X + \log_a Y$$

$$\log_a \left(\frac{Y}{X}\right) = \log_a Y - \log_a X$$

$$\log_a \left(\frac{1}{X}\right) = -\log_a X$$

$$\log_a (X^y) = y \log_a X$$

$$\log_a X = \frac{\log_b X}{\log_b a}$$

(밑변환 공식)

3. 로그함수의 미분

네이피어 상수(Napier`s constant) = e =$\lim_{h \to 0}(1+h)^{\frac{1}{h}}$=2.71727..

자연로그(natural logarithm) = $\log_e x$ (e를 밑으로 하는 로그함수)

네이피어 상수를 파이썬으로 확인하기 (->napiers_constant.py)

$$y = \log_a x$$

$$y' = \frac{1}{xlna}$$

$$y = logx$$

$$y' = \frac{1}{x}$$

4. 지수함수의 미분

$$(e^x)' = e^x$$

$$(a^x)' = (\log(a))a^x$$

5. 시그모이드

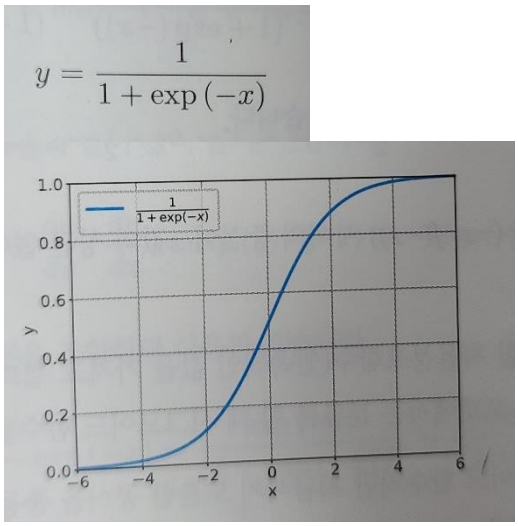

시그모이드 함수 특징

- 값이 항상 증가하는 함수다.
- x값이 음의 무한대로 갈때 함숫값은 0에 가까워진다.
- x값이 양의 무한대로 갈때 함숫값은 1에 가까워진다.
- x=0일때 함숫값은 0.5이다.
- 그래프 모양은 점(0,0.5)에 점대칭이다.

마지막 특징은 다음의 계산으로 확인할 수 있습니다.

$$f(x) = \frac{1}{1+\exp(-x)}$$

$f(x)$가 위와 같을 때 다음 식이 성립합니다.

$$\begin{aligned} f(x)+f(-x) &= \frac{1}{(1+\exp(-x))} + \frac{1}{(1+\exp(x))} \\ &= \frac{1}{(1+\exp(-x))} + \frac{\exp(-x)}{(1+\exp(-x))} = 1 \end{aligned}$$

위 식을 정리하면 다음과 같이 쓸 수 있습니다.

$$\frac{1}{2}(f(x)+f(-x)) = \frac{1}{2}$$

이것은 두 개의 점 $(x, f(x))$와 $(-x, f(-x))$ 사이의 중점이 x값과 상관 없이 항상 $\left(0, \frac{1}{2}\right)$에 있다는 것을 의미합니다.

6. 시그모이드 미분 하는 방법

u(x)=1+exp(-x) 라고 하면 y(u)=$\frac{1}{u}$가 된다.

여기다가 합성함수의 미분 공식을 적용하면 다음과 같다.

$$\frac{dy}{dx} = \frac{dy}{du}\frac{du}{dx}$$

$$\frac{dy}{du} = \left(\frac{1}{u}\right)' = -\frac{1}{u^2}$$

이번에는 우변의 오른쪽 부분인 $\frac{du}{dx}$에서 합성함수의 미분 공식을 써 봅시다. $v = -x$라고 할 때 u와 v는 다음과 같은 관계가 됩니다.

$$u = 1 + \exp(-x) = 1 + \exp(v)$$

따라서 우변의 오른쪽 부분은 다음과 같이 풀어 쓸 수 있습니다.

$$\frac{du}{dx} = \frac{du}{dv} \cdot \frac{dv}{dx} = \exp(v) \cdot (-1) = -\exp(-x)$$

우변의 왼쪽 부분과 오른쪽 부분을 조합하면 다음과 같습니다.

$$\begin{aligned} \frac{dy}{dx} &= -\frac{1}{u^2} \cdot -\exp(-x) = \frac{\exp(-x)}{(1+\exp(-x))^2} = \frac{1+\exp(-x)-1}{(1+\exp(-x))^2} \\ &= \frac{1}{1+\exp(-x)} - \frac{1}{(1+\exp(-x))^2} = y - y^2 = y(1-y) \end{aligned}$$

결론적으로 수식을 정리하면 다음과 같이 쓸 수 있습니다.

$$f'(x) = y(1-y) \qquad (5.5.1)$$

(시그모이드 미분결과)

f'(x)=y(1-y)

7. 소프트맥스 함수

앞에서 소개한 시그모이드 함수는 실수를 입력하면 (확률값으로 해석할 수 있는) 0에서 1까지의 값을 출력하는 함수였다.

소프트맥스(softmax) 함수는 벡터를 입력하면 (확률값으로 해석할 수 있는) 0에서 1까지의 값을 가진 같은 차수의 벡터를 출력하는 함수다. 기능도 시그모이드 함수와 비슷하고 출력 결과도 확률값으로 쓸 수 있는 함수이다.

g(x1,x2,x3)=exp(x1)+exp(x2)+exp(x3)

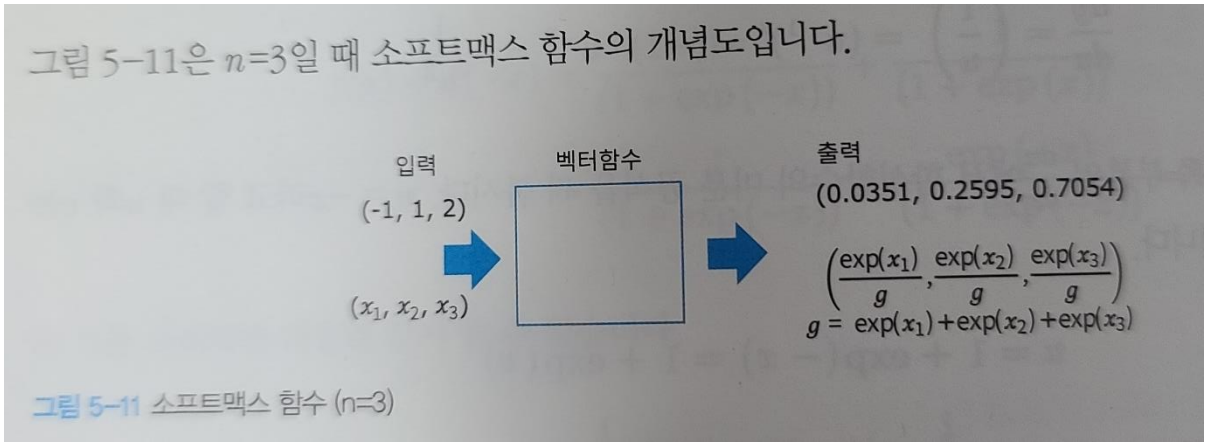

$$\begin{cases} y_1 = \dfrac{\exp(x_1)}{g(x_1, x_2, x_3)} \\ y_2 = \dfrac{\exp(x_2)}{g(x_1, x_2, x_3)} \\ y_3 = \dfrac{\exp(x_3)}{g(x_1, x_2, x_3)} \end{cases}$$

소프트맥스 함수의 정의에 의해 다음 식이 성립한다.

y1+y2+y3=1

$0 \le y_i \le 1 \ (i = 1,2,3)$

우선 x와 y의 첨자가 같은 경우로 y_1을 x_1로 편미분해 봅시다. 수식이 간결해지도록 $\exp(x_1)$을 $h(x_1)$으로 표기하겠습니다.

$$y_1 = \frac{h(x_1)}{g(x_1, x_2, x_3)} = \frac{h}{g}$$

2.8절에서 설명한 몫의 미분 공식 (2.8.1)에 의해 위의 식을 다음과 같이 쓸 수 있습니다[10].

$$\frac{\partial y_1}{\partial x_1} = \frac{g \cdot h_{x_1} - h \cdot g_{x_1}}{g^2}$$

위 식에서 h_{x1}과 g_{x1}을 따로 풀어보면 다음과 같습니다.

$$h_{x_1} = \exp(x_1)' = \exp(x_1) = h$$

$$g_{x_1} = \frac{\partial g}{\partial x_1} = \exp(x_1) = h$$

이들을 조합하면 다음과 같은 결과가 나옵니다.

$$\frac{\partial y_1}{\partial x_1} = \frac{g \cdot h - h \cdot h}{g^2} = \frac{h}{g} \cdot \frac{g - h}{g} = \frac{h}{g} \cdot \left(1 - \frac{h}{g}\right) = y_1(1 - y_1)$$

지금까지 x와 y의 첨자가 같을 때의 편미분 결과를 봤습니다. 그러면 x와 y의 첨자가 같지 않은 경우는 어떻게 될까요? 이해를 돕기 위해 y_2를 x_1로 편미분하는 경우를 예로 들어 보겠습니다.

$$y_2 = \frac{\exp(x_2)}{g(x_1, x_2, x_3)} = \frac{h(x_2)}{g}$$

이때 분자 부분은 x_1의 관점에서 상수($h' = 0$)로 볼 수 있고 몫의 미분 공식을 사용하면 다음과 같이 식을 쓸 수 있습니다.

$$\frac{\partial y_2}{\partial x_1} = \frac{g \cdot h(x_2)_{x_1} - h(x_2) \cdot g_{x_1}}{g^2} = \frac{g \cdot 0 - h(x_2) \cdot g_{x_1}}{g^2} = -\frac{h(x_2) \cdot g_{x_1}}{g^2}$$

g_{x_1}은 g를 x_1로 편미분한 결과이므로 앞의 계산 결과에 의해 $h(x_1)$이 됩니다.

$$\frac{\partial y_2}{\partial x_1} = -\frac{h(x_2) \cdot h(x_1)}{g^2} = -\frac{h(x_2)}{g} \cdot \frac{h(x_1)}{g} = -y_2 \cdot y_1$$

이제까지의 내용을 정리하면 다음과 같습니다.

$$\frac{\partial y_j}{\partial x_i} = \begin{cases} y_i(1 - y_i) & (i = j) \\ -y_i y_j & (i \neq j) \end{cases} \tag{5.6.1}$$

이것이 **소프트맥스 함수의 편미분 결과**입니다.

n=2일때의 소프트맥스 함수는 사실상 시그모이드 함수와 동일

n=3 이상으로 확장한 것이 소프트맥스 함수라고 볼수 있다.

칼럼 시그모이드 함수와 소프트맥스 함수의 관계

지금까지의 계산 결과를 보면 시그모이드 함수와 소프트맥스 함수 사이에 어떤 관계가 있는 것으로 보여집니다. 이러한 생각은 $n = 2$일 때 소프트맥스 함수에 다음 계산을 해 보면 사실이라는 것을 알 수 있습니다. 참고로 마지막 수식은 분자와 분모를 $\exp(x_1)$로 나누고 5.1절에서 도출한 지수함수의 공식 (5.1.9)를 적용했습니다.

$$y_1 = \frac{\exp(x_1)}{\exp(x_1) + \exp(x_2)} = \frac{1}{1 + \exp(-(x_1 - x_2))}$$

이때 $x_1 - x_2$를 x로 대체하면 시그모이드 함수와 같은 식이 되는 것을 알 수 있습니다. 즉, $n = 2$일 때의 소프트맥스 함수는 사실상 시그모이드 함수와 동일하며, 반대로 시그모이드 함수를 $n = 3$ 이상으로 확장한 것이 소프트맥스 함수라고 볼 수 있습니다. 이러한 시그모이드 함수와 소프트맥스 함수 간의 관계는 뒤에 나올 실습편에서 8장의 이진 분류와 9장의 다중 클래스 분류의 관계로 연결되니 참고하기 바랍니다.

Chapter 6. 확률과 통계

분류를 하기 위한 지도학습 모델 중에서 딥러닝과 관련이 깊은 것으로 로지스틱 회귀가 있다. 로지스틱 회귀 모델은 확률을 빼놓고 설명하기 힘든데 어떤 입력 데이터가 어느 클래스에 속하는지 예측하려면 그 클래스에 속할 확률값을 알아야하기 때문이다.

측정값에서 만들어진 확률 모델로부터 가장 높은 확률을 끌어내기 위해 최적의 매개변수를 찾는 것을 최대가능도 추정이라고 한다. 최대가능도 추정은 로지스틱 회귀모델의 학습 과정에서 근간이 되는 개념이다.

확률 표기 방법 P(X),P(Y) , X와 Y를 확률변수라고 한다.

(주의 : 함수는 f(x),g(x) 처럼 앞글자로 구분하는 반면 확률에서는 서로다른 확률을 쓸때 P(X),P(Y)와 같이 뒤의 글자로 구분한다.)

ex) X: 동전을 한번 던졌을 때 나오는 동전의 면

Y: 주사위를 한번 던졌을때 나오는 주사위의 숫자

X와 Y의 각 경우의 수는 다음과 같다.

X={앞면,뒷면}의 2개의 값

Y={1,2,3,4,5,6}의 6개의 값

P(X=앞면)=1/2

P(Y=2)=1/6

확률변수가 가질 수 있는 값과 그에 대한 확률을 표 형태로 정리한 것을 확률분포라고 한다.

표 6-2 X의 확률분포

확률변수 X	앞면	뒷면
$P(X)$	1/2	1/2

표 6-3 Y의 확률분포

확률변수 Y	1	2	3	4	5	6
$P(Y)$	1/6	1/6	1/6	1/6	1/6	1/6

확률변수를 조금더 확장해보면 예를 들어 동전을 n번 던졌을 때 앞면이 나오는 횟수라고 정의할 수 있다. --> X_n

결과가 성공(1)이나 실패(0)로 나오는 독립시행을 n번 했을 때 성공(1)이 나오는 횟수를 확률변수라고 할때 이에 대한 확률분포를 이항분포(binomial distribution)라고 한다.

$n=1, 2, 3, 4$일 때의 이항분포를 표로 나타내면 다음과 같습니다.

표 6-4 이항분포의 확률분포

동전의 앞면을 H, 뒷면을 T라고 할 때 앞면이 나오는 횟수를 확률변수라고 하면

$n=1$인 경우

확률변수 X_1	0	1
$P(X_1)$	1/2	1/2
동전	T	H

$n=2$인 경우

확률변수 X_2	0	1	2
$P(X_2)$	1/4	2/4	1/4
동전	TT	HT, TH	HH

$n=3$인 경우

확률변수 X_3	0	1	2	3
$P(X_3)$	1/8	3/8	3/8	1/8
동전	TTT	HTT, THT, TTH	HHT, HTH, ..., THH	HHH

$n=4$인 경우

확률변수 X_4	0	1	2	3	4
$P(X_4)$	1/16	1/16	6/16	4/16	1/16
동전	TTTT	HTTT, ..., TTTH	HHTT, ..., TTHH	HHHT, ..., THHH	HHHH

확률분포의 표는 막대 그래프로도 표현할 수 있는데 이 그래프를 히스토그램이라고 한다.

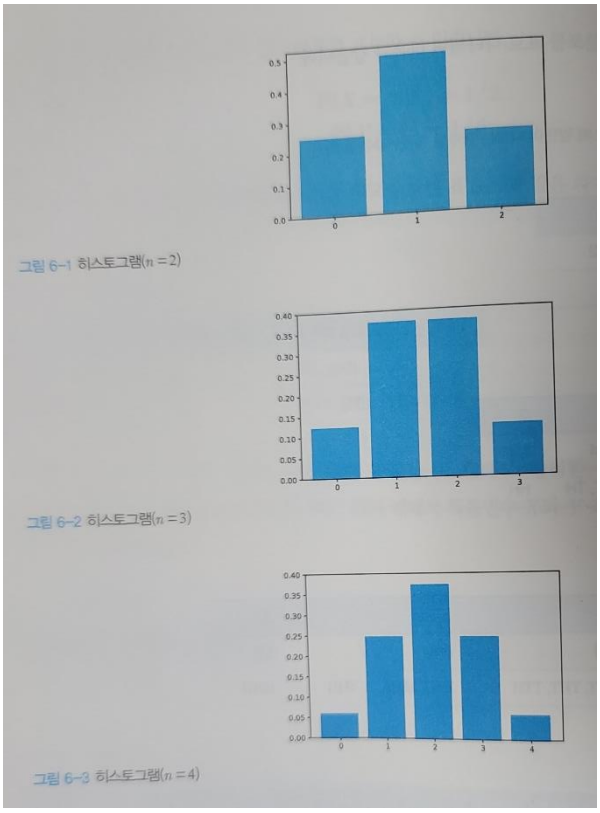

n이 커지게 되면은 우측 그림과 같아진다.

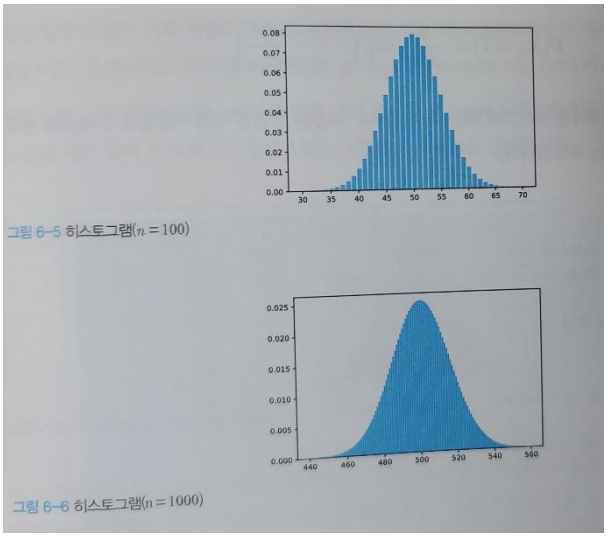

이처럼 이항분포의 히스토그램은 n 값이 커질수록 연속함수(continuous function)의 모양이 된다.

이 함수는 정규분포(normal distribution)함수라고 하며 다음과 같은 식으로 표현된다.

P($X_1 = 1$)=p (한번 시행했을때의 확률) 라고 할때 $E(X) = \mu = np$이고 $V(X) = \sigma^2 = np(1-p)$일때 확률(증명 : https://hsm-edu.tistory.com/61 에서 확인하기)

$$f(x, \mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

($\mu =$ *평균*, $\sigma =$ *표준편차*, $\sigma^2 =$ *분산*)

또한 이항분포함수가 정규분포함수에 가까워지는 것을 중심극한정리(central limit theorem)라고 한다. 앞의 예에서 동전을 한번 던졌을때 결과가 1이나올 확률은 p=1/2 이므로 μ=np=n/2 이고 σ^2=np(1-p)=n/4 가된다. n/2=m이라고 놓으면 근사식을 다음과 같이 쓸수 있다..

$$P(X_n = x) \approx \frac{1}{\sqrt{m\pi}} \exp\left(-\frac{(x-m)^2}{m}\right)$$

정규분포함수처럼 확률변수가 연속적인 값을 가질때 확률분포함수는 연속함수이다. 이때의 확률분포함수를 확률밀도함수라고 한다.

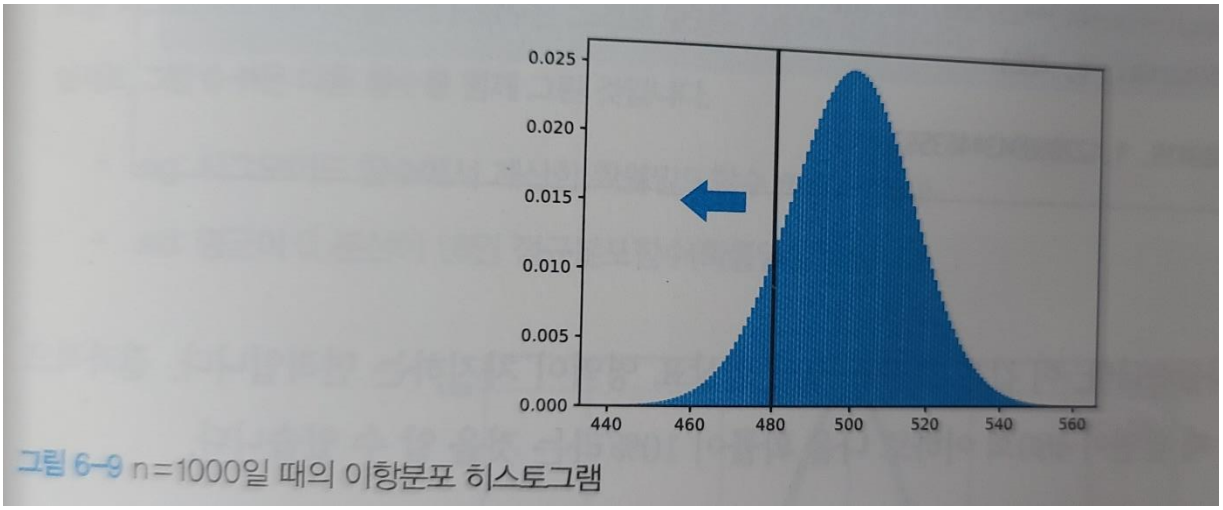

그림 6-9 n=1000일 때의 이항분포 히스토그램

n=1000인 그래프가 정규분포를 따를 때의 확률 값을 구해보라

이 그래프는 아주 작은 사각형으로 구성돼 있는데 모든 사격형의 면적을 합하면 1이 된다.

P($X_{1000} \leq 480$) 이말은 동전을 1000번 던졌을때 앞면이 480번 이하로 나올 확률

이 확률은 그림 6-9에서 화살표로 표시된 영역의 면적과 같습니다. 연속함수의 면적은 곧 적분을 의미합니다(2.9절 참고). 그래서 다음과 같이 적분한 식을 사용하면 근사적인 확률값을 얻을 수 있습니다[7].

$$P(X_{1000} \leq 480) \approx \int_0^{480} f(x)dx$$

앞서 소개한 정규분포함수식에 $m = 1000/2 = 500$을 대입하면 다음과 같이 식을 쓸 수 있습니다.

$$f(x) = P(X_n = x) \approx \frac{1}{\sqrt{500\pi}} \exp\left(-\frac{(x-500)^2}{500}\right)$$

적분 결과 약 0.1 이 나왔다. 1000번 던질때 앞면이 480회 이하로 나올 확률이 10% 라는것이다.

이처럼 어떤 사건의 누적된 확률을 계산하고 싶을 때는 확률밀도함수를 적분하면 된다. 확률밀도함수를 적분해서 구한 함수를 누적분포함수라고한다.

칼럼 정규분포함수와 시그모이드 함수

지금까지 설명한 내용으로 눈치챘을지도 모르겠지만 어떤 실숫값에서 확률값을 구할 때 정규분포함수를 쓰는 것은 자연스러운 접근법입니다. 다만 머신러닝 모델에서는 확률값을 구할 때 일반적인 정규분포함수 대신 시그모이드 함수를 사용합니다.

가장 큰 이유로는 확률밀도함수가 정규분포일 때 적분 결과(확률분포함수)를 함수식으로 표현하지 못하는 경우가 있기 때문입니다.

반대로 확률분포함수가 다음과 같은 시그모이드 함수일 때

$$f(x) = \frac{1}{1 + \exp(-x)}$$

이 식의 미분(확률밀도함수)은 원래의 함수식만으로도 구할 수 있습니다.

$$f'(x) = f(x)(1 - f(x))$$

누적분포함수 = 시그모이드함수f(x)

확률밀도함수 = f(x)(1-f(x))

확률밀도함수를 적분하면 누적분포함수가 나온다. 시그모이에서 0.5보다 작으면 0으로 치고 0.5보다크면 1로 치는것이 누적분포함수이기 때문이다 .

또한 시그모이드 함수와 누적분포함수는 그래프 모양도 상당히 비슷하다.

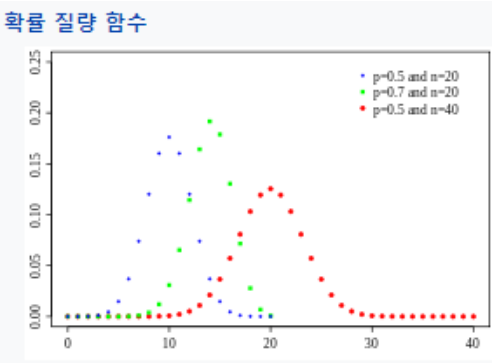

확률질량함수(확률밀도함수)

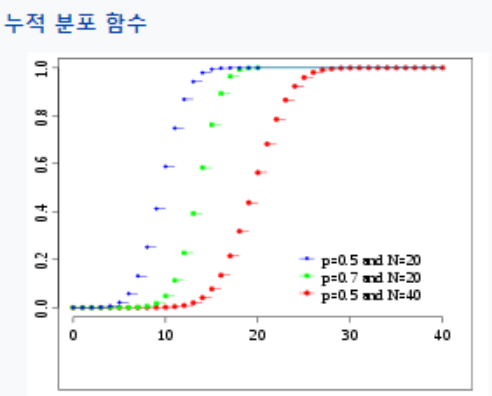

누적분포함수가 시그모이드 함수와 상당히 유사함을 알 수 있다.

가능도함수와 최대가능도 추정

제비뽑기 당첨나올확률 항상 일정 이 기계에서 뽑기를 여러번 할때 각 시행은 이전 시행과는 관계없는 독립적인 시행이다. 다섯번 제비를 뽑아보니 첫번째와 네번째에 당첨이 나오고 나머지 세번은 당청미되지 않았다. 제비를 한번 뽑았을 때 당첨될 확률을 p 라고 할때 가장 가능성이 높은 확률 p를 구하시오

확률변수 X_i을 다음과 같이 정의합니다.

$$X_i = \begin{cases} 1 & \text{(당첨인 경우)} \\ 0 & \text{(당첨이 아닌 경우)} \end{cases}$$

당첨될 확률이 p일 때 당첨되지 않을 확률은 $(1-p)$이므로 위의 다섯 번의 시행 결과를 표로 정리하면 다음과 같습니다.

표 6-5 5번의 시도에 대한 확률

i	X_i	$P(X=X_i)$
1	1	p
2	0	$1-p$
3	0	$1-p$
4	1	p
5	0	$1-p$

첫 번째와 네 번째가 당첨이고 나머지는 당첨이 아닌 확률은 각 사건의 확률을 곱한 것과 같으며 다음과 같은 식으로 표현할 수 있습니다.

$$\begin{aligned} &P(X=X_1)\cdot P(X=X_2)\cdot P(X=X_3)\cdot P(X=X_4)\cdot P(X=X_5) \\ &= p\cdot(1-p)\cdot(1-p)\cdot p\cdot(1-p) \\ &= p^2\cdot(1-p)^3 \end{aligned}$$

모델의 확률적 특징을 나타내는 변수를 포함한 식을 가능도함수

이 가능도함수를 미분했을때 그값이 0이 되게하는 매개변숫값을 구한다음 그값을 가장 확률이 높은 매개변수로 추정하는 알고리즘을 최대가능도 추정이라고 한다.

$$\log(p^2(1-p)^3) = 2\log p + 3\log(1-p) \tag{6.3.2}$$

수식 (6.3.2)를 p로 미분해서 결과가 0이 되는 방정식을 만들면 다음과 같습니다.

$$\begin{aligned} \frac{2}{p} + \frac{3\cdot(-1)}{1-p} &= 0 \\ 2(1-p) - 3p &= 0 \\ 5p &= 2 \\ p &= \frac{2}{5} \end{aligned}$$

최대가능도 추정을 할때는 원래 식 전체에다가 로그를 적용한다. 로그를 쓰는 이유는 로그함수가 단조증가함수이기 때문에 원래의 함수에서 최댓값이 나오는 매개변수와 로그를 적용한 후의 함수에서 최댓값이 나오는 매개변수가 똑같고 너무크거나 작은수를 다루기에 용이하기 때문이다.(계산하기도 용이)

5번 시도에서 2번이 성공했기 대문에 2/5의 확률 이라고 하는 상식적인 수준의 예측과 똑같이 나왔다.

추정방법 요약

1. 측정값(Xi)과 매개변수(p)를 포함한 식을 만든다.

2. 확률식에 측정값(Xi 의 실제값)을 대입해서 매개변수만 있는 식으로 만든다.

3. 2의 식을 매개변수의 함수로 보고 로그를 적용한 다음 매개변수로 미분한 결과가 0이 됐을 때의 매개변숫값을 구한다.

(가능도함수의 극값은 항상 최댓값이다 산모양이기때문에)